

Tarea 2 • Expediente de datos

Clasificación, riesgo de reidentificación y anonimización

Modalidad	En parejas. Las mismas de la Tarea 1, salvo que se acuerde lo contrario.
Se entrega	Miércoles 23 de septiembre de 2026, hasta las 23:59, en la ayudantía de cierre con Nicolás Vásquez.
Ponderación	RA1 • forma parte del 40 % de tareas del curso.
Qué se entrega	Un notebook <code>tarea2_apellido1_apellido2.ipynb</code> y su exportación a PDF. Nada más: el informe va dentro del notebook, en celdas de texto.
Datos	<code>matriculas_liceo.csv</code> e <code>inscritos_campeonato.csv</code> , ambos en el ZIP de Canvas.

El encargo. El Liceo Bicentenario Costa del Biobío quiere publicar un informe con sus indicadores de rendimiento y asistencia, y además compartir la base con una universidad que hará un estudio sobre deserción escolar. Antes de entregar nada, la dirección les pide a ustedes un **expediente de datos** que determine qué se puede compartir, en qué condiciones y con qué riesgos. El archivo incluye estudiantes menores de edad, lo que eleva el estándar de cuidado.

SECCIÓN 1 • CLASIFICACIÓN DE LOS DATOS • 20 puntos

Carguen ambos archivos y describan la base principal: filas, columnas, tipos y período. Luego construyan una tabla que clasifique **cada una** de las 13 columnas en: identificador directo, cuasi-identificador, dato sensible o atributo operacional.

- La tabla debe ir en el notebook como DataFrame, no como texto suelto.
- Justifiquen en una celda de texto las columnas que clasificaron como sensibles y por qué. Hay al menos dos, y una de ellas suele pasarse por alto.
- Indiquen qué columnas cree usted que el liceo **no debería estar guardando** para la finalidad declarada, y por qué.

SECCIÓN 2 • RIESGO DE REIDENTIFICACIÓN • 25 puntos

Produzcan una versión «anonimizada» eliminando los identificadores directos, y luego demuestren con datos que **no basta**.

- Midan cuántos estudiantes quedan solos en su combinación de cuasi-identificadores.
- Ejecuten el ataque de reidentificación cruzando con `inscritos_campeonato.csv`. Reporten cuántos estudiantes recuperan su nombre.
- Muestren un ejemplo concreto: un estudiante reidentificado junto al dato sensible que quedó expuesto. Basta una fila.
- Calculen el k-anonimato de la base e interpreten el valor en una frase.

SECCIÓN 3 • ANONIMIZACIÓN • 25 puntos

Construyan una versión publicable que alcance $k \geq 5$, combinando generalización y supresión.

- Apliquen al menos dos generalizaciones distintas y expliquen el criterio de cada una.
- Supriman lo que siga bajo el umbral, e informen cuántas filas se perdieron y qué porcentaje representan.
- Verifiquen el k final con la misma función con que lo midieron antes.
- **Midan la utilidad conservada:** elijan un indicador que al liceo le importe —por ejemplo el promedio de notas por curso, o la asistencia por programa de apoyo— y compárenlo entre la base original y la publicable. Comenten si la diferencia es aceptable.

SECCIÓN 4 • SEUDONIMIZACIÓN • 15 puntos

El liceo necesita seguir a cada estudiante entre semestres, así que no puede borrar el identificador del todo. Implementen una seudonimización correcta.

- Generen un seudónimo estable para el RUT usando HMAC con una sal.
- Expliquen en una celda de texto por qué un hash sin sal no protege un RUT chileno. Si quieren, demuéstrenlo con código.
- Respondan: la base seudonimizada, ¿sigue siendo de datos personales? Fundamenten.

SECCIÓN 5 • POLÍTICA DE ACCESO • 15 puntos

Propongan la política de acceso del liceo para esta base, como tabla, y aumentenla con al menos una función en Python que la haga efectiva.

- Consideren al menos cuatro roles: dirección, profesor jefe, equipo psicosocial y el investigador externo.
- Para cada rol: qué columnas ve, sobre qué alcance y si puede modificar.
- Escriban una función **vista(df, rol)** que devuelva la porción correspondiente, y muestren su salida para dos roles.
- Cierren con un párrafo: qué le entregarían finalmente a la universidad y bajo qué condición.

Criterio	Pts	Qué se espera	Qué descuenta
1 · Clasificación	20	Las 13 columnas clasificadas, con los datos sensibles correctamente identificados y justificados.	Clasificar por intuición sin justificar; omitir alguno de los datos sensibles.
2 · Riesgo	25	El ataque ejecutado y cuantificado, con un caso concreto mostrado y el k interpretado.	Reportar el número sin mostrar el cruce; confundir k con un promedio.
3 · Anonimización	25	$k \geq 5$ alcanzado, con generalizaciones justificadas y la pérdida de utilidad medida.	Llegar a $k \geq 5$ suprimiendo media base; no comparar la utilidad antes y después.
4 · Seudonimización	15	HMAC con sal correctamente implementado y la pregunta legal respondida con fundamento.	Usar hash simple; responder que ya no son datos personales.
5 · Política de acceso	15	Cuatro roles con alcance definido y la función operativa devolviendo lo que corresponde.	Una tabla sin función; roles que ven todo «por si acaso».

Cómo se corrige. No se evalúa que el código corra: se evalúa **el criterio**. Una anonimización modesta bien argumentada vale más que una sofisticada sin explicación. Cada sección debe cerrar con una celda de texto que interprete el resultado; sin ella, la sección se considera incompleta.

REGLAS DE TRABAJO

- 1. Trabajo en parejas.** Ambos nombres en la primera celda del notebook. Se corrige una sola entrega por pareja.
- 2. Uso de asistentes de IA.** Permitido para consultar y depurar. Las decisiones sobre los datos y su justificación deben ser suyas, y se les puede pedir explicarlas en la ayudantía. Una justificación que la pareja no sabe defender se descuenta.
- 3. Atrasos.** Descuento de 10 puntos por día corrido. Después de 48 horas no se recibe.
- 4. Los datos son sintéticos.** Fueron generados para esta actividad. Aun así, trátenlos con el mismo cuidado que exigirían para datos reales: es parte de lo que se practica.